EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

S5 Rapport Hebdomadaire

24 mars 2026

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Étudiant	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse

RÉSUMÉ DE LA SEMAINE

Audit de l'anonymisation sur 900 fichiers (50 par type, 18 catégories). **100%** de couverture sur emails, téléphones, adresses, IBAN, AVS. **96.1%** sur les noms. Deux axes d'amélioration : numéros de passeport sur les certificats IELTS et noms résiduels dans les diplômes étrangers.

MÉTHODOLOGIE

Échantillon aléatoire stratifié de **900 fichiers** (graine = 42) sur les 18 types de documents du corpus de 12 529 fichiers Markdown anonymisés. Détection par regex ciblées sur les PII à haut risque (emails, passeports, noms, URLs) + vérification manuelle des cas limites.

Pipeline audité : **Presidio** + **GLiNER** (`gliner-multitask-large-v0.5`) + **spaCy**, avec reconnaisseurs personnalisés (AVS, SCIPER), propagation de noms, et 8 filtres post-analyse.

RÉSULTATS

FICHIERS AUDITÉS	REDACTIONS	EMAILS NON REDACTÉS	NOMS RÉSIDUELS
900	**22 494**	**0**	**35**
sur 12 529 (7.2%)	dans l'échantillon	100% couverture	3.9% des fichiers

Type de PII	Redactions	Fuites	Couverture	Risque
Emails	1 499	0	100%	FAIBLE
Téléphones	1 467	0	100%	FAIBLE
Adresses	1 841	0	100%	FAIBLE
URLs	1 267	0	100%	FAIBLE
AVS / IBAN / SCIPER	33	0	100%	FAIBLE
Noms de personnes	9 442	35	96.1%	MOYEN
Numéros de passeport	—	23	n/a	MOYEN

Tableau 1. – Couverture par type de PII sur l'échantillon de 900 fichiers.

i NOTE

`<DOB_YYYY>` préserve l'année de naissance (ex: `<DOB_1995>`) — intentionnel pour évaluer l'adéquation du profil. Ce n'est pas un identifiant direct.

PROBLÈMES IDENTIFIÉS AVEC EXEMPLES

Problème 1 — Noms en ALL CAPS non détectés par GLiNER

Les diplômes et certificats étrangers utilisent des majuscules complètes. GLiNER ne reconnaît pas ces noms comme entités `PERSON`.

Fichier	Extrait anonymisé (nom visible)
GRE Score Report	`ZHANG` Most Recent Test Date: <DATE>
Diplôme colombien	`JARAMILLO VÉLEZ` ID Card No. <PII>
GMAT Report	`KOLLIA` Graduate Management…

Tableau 2. – Noms en majuscules non redactés — GLiNER échoue sur le casing ALL CAPS.

Problème 2 — Noms partiellement redactés

Le tokenizer sépare prénom et nom en entités distinctes. Le prénom est parfois redacté, mais le nom de famille reste visible.

Fichier	Extrait
Lettre de recommandation	`<PERSON> Perdomo` — le nom de famille reste
Lettre de motivation	`<PERSON> LAW` — idem en majuscules
Relevé de notes	`<PERSON> Angulo's application` — possessif

Tableau 3. – Redaction partielle — le prénom est anonymisé mais le nom de famille persiste.

Problème 3 — Noms dans les formulaires structurés (Synthèse IS-Academia)

Les synthèses de candidature ont un format tabulaire `Nom / Prénom` où le nom est isolé sur une ligne, non reconnu comme entité.

```
Données personnelles
Nom
Lois              ← non redacté
Nom <PERSON>      ← prénom redacté
```

Tableau 4. – Formulaire IS-Academia : le nom est isolé et échappe au NER.

Problème 4 — Numéros de passeport sur les certificats IELTS/TOEFL

20% des certificats linguistiques contiennent un numéro de passeport non redacté. Le pipeline supprime les *scans* de passeport (`strip_passports.py`) mais pas les numéros *textuels* apparaissant dans d'autres documents.

Document	Valeur	Contexte
IELTS e-TRF	`Z5295128`	Passeport sur rapport IELTS
IELTS Certificate	`YB3289203`	Passeport candidat
IELTS Result	`B9861485`	Passeport candidat
Diplôme étranger	`BH616353`	Passeport marocain

Tableau 5. – Numéros de passeport non détectés dans les certificats linguistiques.

CORRECTIFS PROPOSÉS

Fix 1 — Propagation du nom depuis les métadonnées du dossier

Actuellement, `_propagate_detected_names` ne propage que les noms *déjà détectés* par GLiNER. Le fix : injecter le nom du candidat depuis le chemin du dossier (ex: `jaramillo_velez` → `["Jaramillo", "Vélez"]`) **avant** l'analyse, en tant que noms à redacter systématiquement.

```
# Dans anonymize_text(), avant l'appel à _propagate_detected_names :
candidate_name = extract_name_from_path(file_path)
# Injecter des RecognizerResult synthétiques pour chaque variante
```

```
# (original, UPPER, Title) du nom du candidat
for variant in name_variants(candidate_name):
    for match in re.finditer(re.escape(variant), text, re.IGNORECASE):
        results.append(RecognizerResult("PERSON", match.start(), match.end(),
0.95))
```

Cela résout les problèmes 1, 2 et 3 simultanément : le nom du candidat est redacté *indépendamment* de ce que GLiNER détecte.

Fix 2 — Reconnaisseur Presidio pour les numéros de passeport

Ajouter un `PassportRecognizer` dans `recognizers.py`, similaire à `AvsAhvRecognizer` :

```
class PassportRecognizer(PatternRecognizer):
    PATTERNS = [
        Pattern("passport_alpha", r"\b[A-Z]{1,2}\d{6,9}\b", 0.4),
    ]
    CONTEXT = ["passport", "passeport", "document number",
               "travel document", "numéro de document"]
```

Score de base à 0.4 (ambiguë) mais boosté par les mots-clés de contexte. Cela couvre les IELTS/TOEFL qui mentionnent « Document Number » ou « Passport » à proximité.

Fix 3 — Filtre de faux positifs pour le reconnaisseur passeport

Pour éviter la sur-redaction (codes cours `CS250112`, matricules), ajouter un filtre dans `post_filters.py` qui exclut les patterns connus :

```
_ACADEMIC_PREFIX = re.compile(r"^(CS|EE|ME|PH|MA|CH|MT)\d+$")

def filter_academic_codes(text, results):
    return [r for r in results
            if r.entity_type != "PASSPORT"
            or not _ACADEMIC_PREFIX.match(text[r.start:r.end])]
```

CONCLUSION

Correctif	Problèmes résolus	Effort
Propagation nom depuis métadonnées	1, 2, 3	30 lignes
Reconnaisseur passeport + filtre	4	40 lignes

Tableau 6. – Deux correctifs ciblés couvrent les 4 problèmes identifiés.

✓ **AVIS GLOBAL**

Le pipeline est opérationnel pour un usage en recherche. **100%** de couverture sur les PII les plus sensibles (emails, adresses, téléphones, IBAN, AVS). Les 70 lignes de correctifs proposés porteraient la couverture des noms au-delà de **99%** et ajouteraient la détection des numéros de passeport.