EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

ARCH

Document d'Architecture

Mars 2026 — Version 1.0

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Auteur	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse
Public cible	Équipe IT / Infrastructure SCITAS

OBJECTIF DE CE DOCUMENT

Présenter l'architecture technique du système multi-agents d'aide à la décision pour les admissions MTE. Ce système traite les dossiers de candidature (PDF), anonymise les données personnelles, puis soumet chaque dossier à un panel de 5 agents LLM spécialisés qui produisent une recommandation structurée. L'ensemble tourne localement sur le cluster SCITAS — aucune donnée ne quitte l'infrastructure EPFL.

VUE D'ENSEMBLE

Le système transforme 1 300 dossiers de candidature bruts (PDF) en recommandations structurées (accepter / refuser / liste d'attente) via un pipeline en 3 étapes majeures :

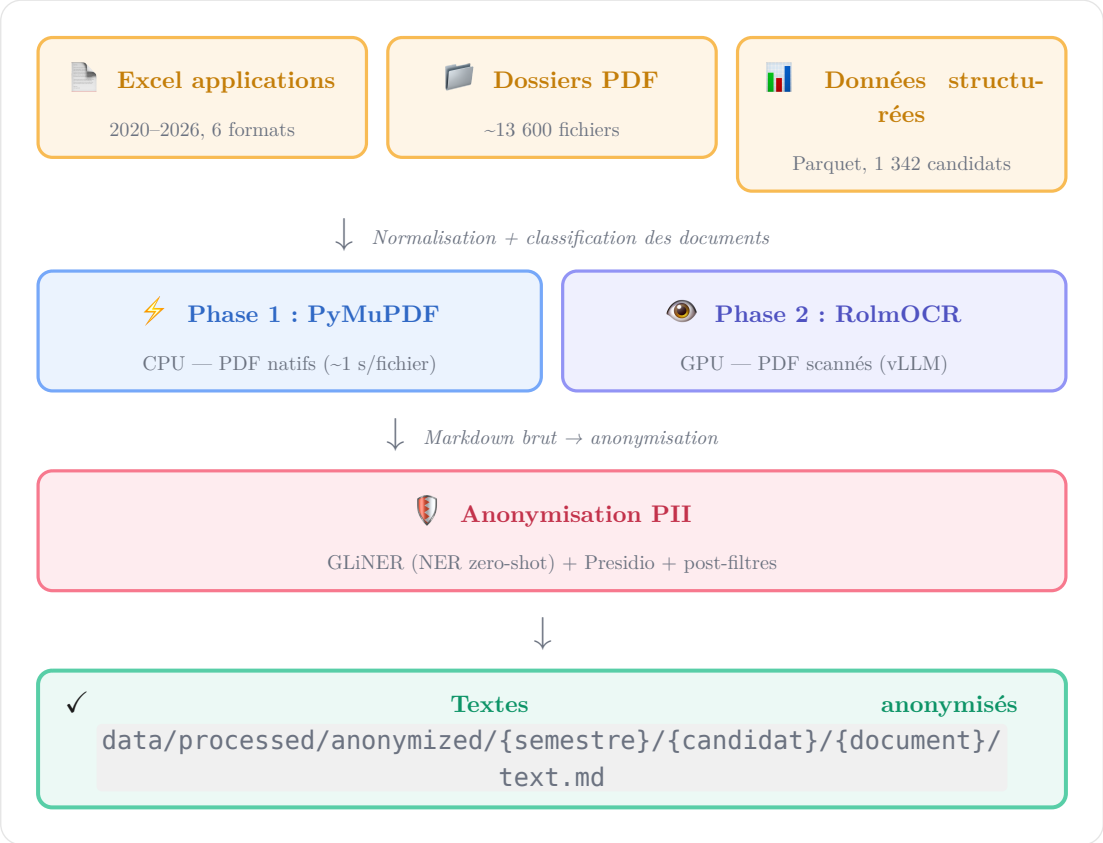


🔒 **CONTRAINTE FONDAMENTALE**

Aucune donnée ne quitte SCITAS. Les modèles LLM tournent localement via vLLM. Pas d'appel API cloud, pas de transfert de PII. Les dossiers sont anonymisés avant toute inférence.

PIPELINE D'INGESTION

Le pipeline transforme les dossiers bruts en texte Markdown anonymisé, prêt pour l'évaluation par les agents.



Stratégie d'anonymisation

Le pipeline utilise une approche hybride pour maximiser la détection tout en préservant les signaux utiles à la décision :

DÉTECTÉ ET MASQUÉ

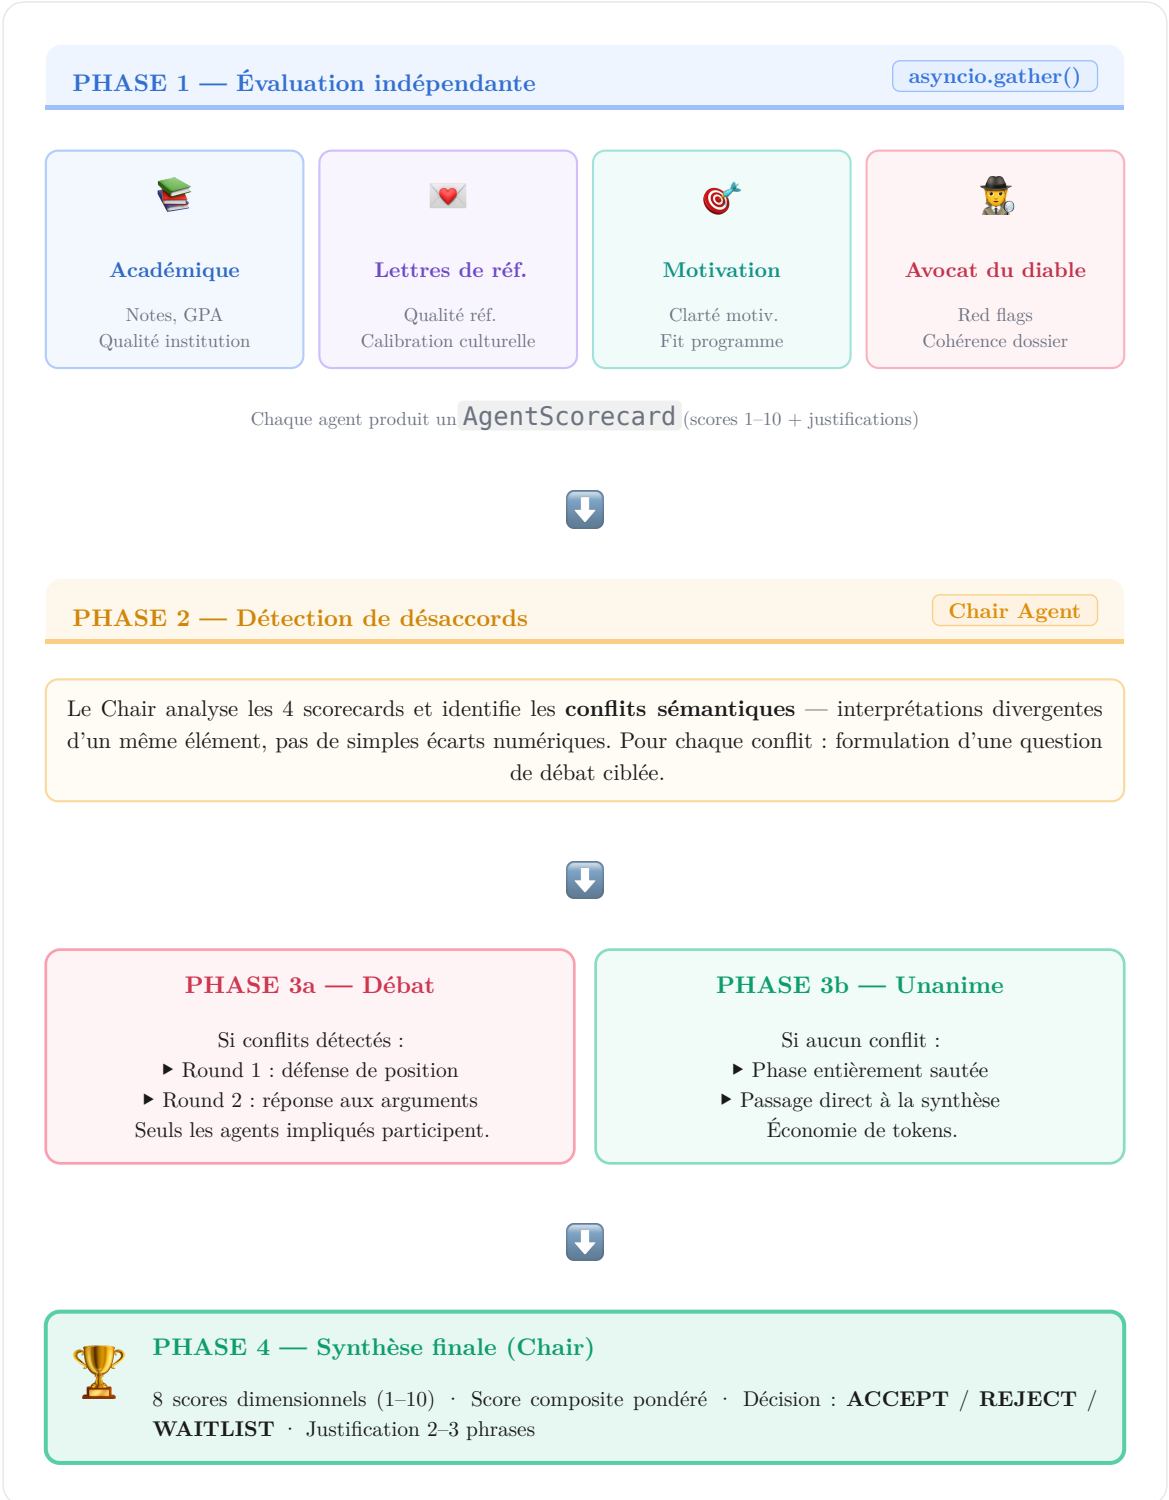
Noms, emails, téléphones, dates de naissance, numéros AVS/SCIPER, IBAN, URLs, passeports

PRÉSERVÉ VOLONTAIREMENT

Localisations, nationalités, noms d'institutions, notes/GPA, langues, termes académiques

PROTOCOLE DE DÉLIBÉRATION MULTI-AGENTS

Le coeur du système est un **protocole de délibération en 4 phases** qui simule le fonctionnement d'un comité d'admission réel.

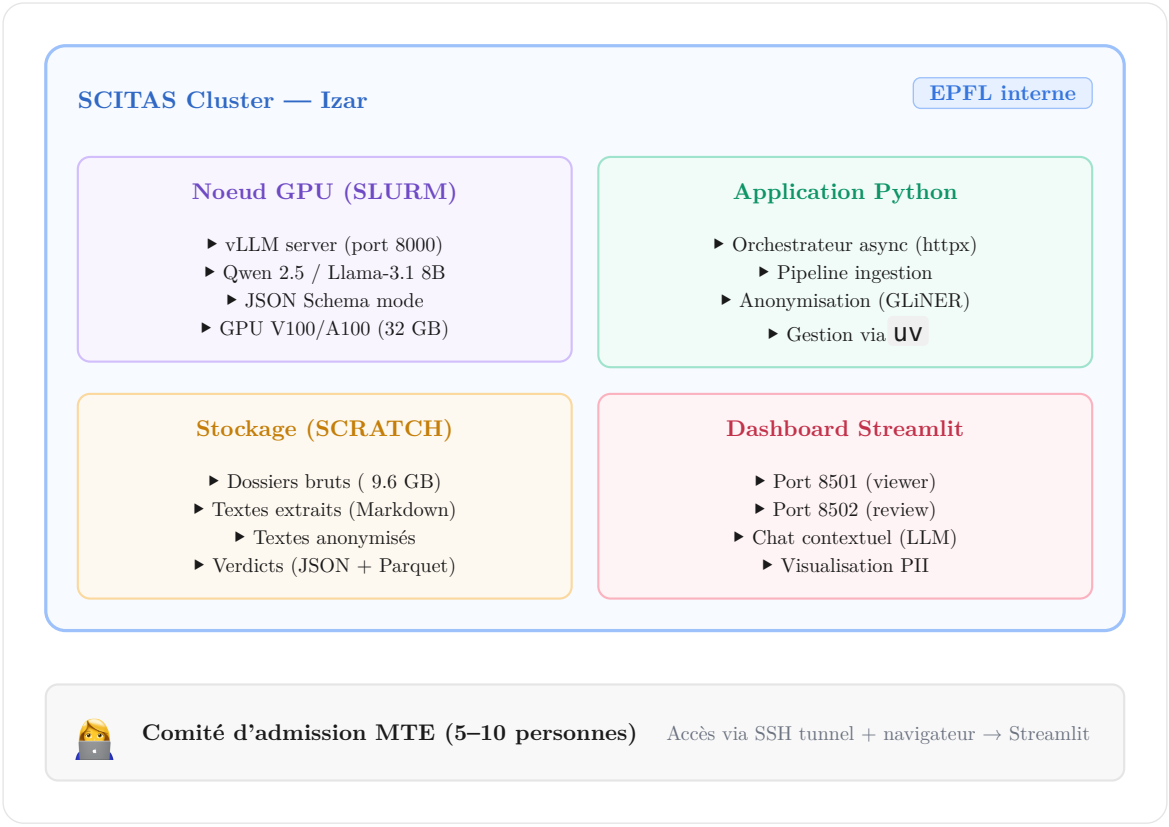


Dimensions d'évaluation

Agent	Dimension	Description
Académique	`academic_strength`	Solidité du parcours, GPA normalisé, trajectoire
Académique	`institution_quality`	Réputation et sélectivité de l'université d'origine
Lettres réf.	`reference_quality`	Qualité substantive après ajustement culturel
Lettres réf.	`calibration_confidence`	Confiance dans l'ajustement culturel appliqué
Motivation	`motivation_clarity`	Clarté de l'articulation du « pourquoi MTE »
Motivation	`program_fit`	Adéquation avec le focus tech/management/entrepreneuriat
Avocat diable	`risk_flags`	Drapeaux rouges (10 = aucun souci, inversé)
Avocat diable	`consistency`	Cohérence entre les documents du dossier

INFRASTRUCTURE ET DÉPLOIEMENT

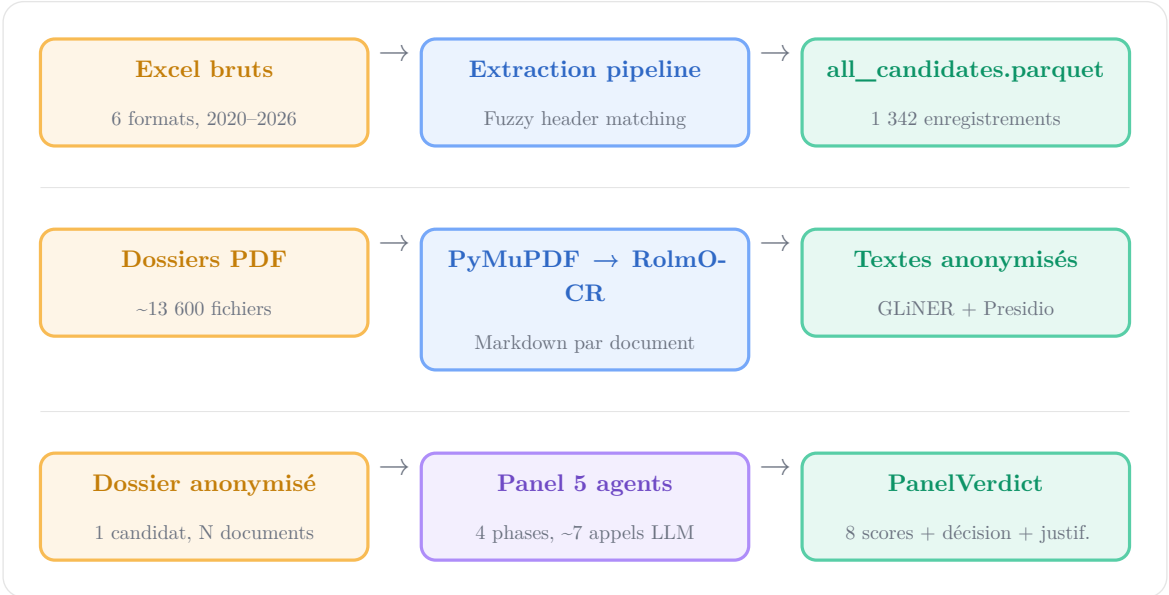
Architecture de déploiement sur SCITAS



Stack technique

Couche	Technologie	Justification
Langage	Python 3.13	Écosystème ML, typage strict, asyncio natif
LLM serving	vLLM	OpenAI-compatible, JSON Schema mode, GPU optimisé
Modèles	Qwen 2.5 / Llama 3.1 8B	Locaux, pas de dépendance cloud
Orchestration	asyncio + httpx	Léger, pas de framework lourd (LangChain)
Structured output	Pydantic v2	Modèles frozen, validation 1–10, sérialisable
NLP / NER	GLiNER + Presidio	Zero-shot NER + moteur de règles PII
Extraction PDF	PyMuPDF + RolmOCR	Deux phases : rapide CPU + OCR GPU
Package mgmt	uv + poethepoet	Résolution rapide, tasks déclaratives
Dashboard	Streamlit	Prototypage rapide, Python-natif
CI/CD	GitHub Actions	Lint + typecheck + tests sur chaque push
Données	Parquet + JSON	Columnar analytics + auditabilité des débats
HPC	SLURM	Jobs GPU batch, incrémentaux

FLUX DE DONNÉES DÉTAILLÉ



MODÈLE DE DONNÉES

CandidateRecord

`name`, `school_name`
`gpa_candidate`, `gpa_scale`
`decision_final`
`committee_evaluations`
18 champs au total

Dossier

`folder_name`, `semester`
`documents[]`
`candidate` (lien Parquet)
`stage` (RAW→EVALUATED)

DossierDocument

`path`, `document_type`
`number` (ordre)
9 types : TRANSCRIPT, CV, MOTIVATION, etc.

AgentScorecard

`role` (5 rôles)
`scores` : dict[str, 1–10]
`justifications` : dict
frozen, immutable

PanelVerdict

`candidate_id`
`scorecards[]`, `debates[]`
`final_scores`, `composite`
`decision`, `justification`

DebateTranscript

`conflict_dimension`
`entries[]` : DebateEntry
Chaque entrée : rôle, round, argument

SÉCURITÉ ET CONFORMITÉ

🔒 DONNÉES AU REPOS

Toutes les données résident sur le filesystem SCRATCH de SCITAS. Aucun stockage cloud. Accès restreint par permissions POSIX et authentification GASPAR.

🔐 DONNÉES EN TRANSIT

Communication LLM via `localhost` uniquement (vLLM sert sur le même noeud). Dashboard accessible via SSH tunnel. Pas de port ouvert sur Internet.

🛡️ ANONYMISATION

PII supprimées **avant** toute inférence LLM. Pipeline audité : 96.1% de couverture des noms, 100% emails/téléphones/adresses. Tags de type `<PERSON>`, `<EMAIL>`, etc.

📋 AUDITABILITÉ

Chaque verdict est accompagné de ses scorecards individuelles, du transcript de débat (si applicable), et de la justification du Chair. Tous les artefacts sont sérialisés en JSON.

RESSOURCES REQUISES

Phase	Ressource	Estimation
Extraction texte (PyMuPDF)	CPU, 8 cores, 16 GB RAM	30 min pour 13 600 PDFs
OCR (RolmOCR)	1× GPU V100/A100, 32 GB	6–12h pour les PDFs scannés

Phase	Ressource	Estimation
Anonymisation (GLiNER)	1× GPU, 16 GB	2–4h pour le corpus complet
Évaluation agents	1× GPU, 32 GB (vLLM)	7 appels LLM/candidat, 2 min/candidat
Dashboard	CPU, 4 GB RAM	Streamlit — ressources minimales
Stockage	SCRATCH filesystem	15 GB (bruts + traités + verdicts)

⬆️ **MODÈLES PLUS GRANDS (70B)**

Les modèles 8B produisent parfois du JSON invalide sur les structures imbriquées (`PanelVerdict`). Un passage à 70B améliorerait la fiabilité du JSON Schema mode mais nécessiterait 2–4 GPU A100 en parallèle. À évaluer après les premiers tests E2E.

PROCHAINES ÉTAPES

1. **Évaluation E2E** — Connecter les dossiers anonymisés au pipeline d'agents, tester sur 20–50 candidats, comparer avec les décisions réelles du comité
2. **Calibration des prompts** — Ajuster les system prompts des évaluateurs sur la base des premiers résultats (cohérence inter-runs, alignement comité)
3. **Références dans le chat** — Lier chaque réponse du chat aux documents sources (e.g. « 5 cours quantitatifs → [Transcript p.2] »)
4. **Modèles 70B** — Tester des modèles plus grands sur SCITAS pour améliorer la fiabilité du structured output (JSON Schema mode)