EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

S1 Rapport Hebdomadaire

24 février 2026

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Étudiant	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse

RÉSUMÉ DE LA SEMAINE

Lancement du projet. Lecture du system design, exploration des données d'admission MTE, demande d'accès aux clusters HPC SCITAS, et recherche sur les modèles de langage open-source exécutables en local.

HEURES INVESTIES	FICHIERS ANALYSÉS	AVANCEMENT GLOBAL
9h	**15**	**5%**
Recherche + Setup	Datasets MTE 2020–2025	Phase: Exploration

Progression du projet 5%

TRAVAIL EFFECTUÉ

Exploration des données

- Inventaire complet des fichiers de candidatures MTE disponibles (2020–2025)
- Analyse de la structure des fichiers Excel: colonnes, format des notes, critères d'évaluation
- Identification des champs récurrents: parcours académique, notes, décisions du comité
- Repérage des incohérences de format entre les différentes années

Recherche sur les modèles open-source

- État de l'art sur les modèles de langage exécutables en local: Llama 3, Mistral, Phi-3, Qwen 3
- Comparaison des performances et des exigences matérielles (GPU vs. CPU-only)
- Revue des approches d'anonymisation des données étudiantes (conformité RGPD)

Accès aux clusters HPC (SCITAS)

- Demande d'accès au compte master HPC via RITM0504113
- Accès confirmé le 19 février 2026: ajout au groupe `hpc-masters`, compte créé avec accès temporaire pour la durée du semestre
- Prochaine étape: connexion via VPN et premiers tests sur les clusters

Mise en place technique

- Initialisation du dépôt Git avec structure de projet
- Configuration de l'environnement Python avec `uv`
- Premiers tests de lecture des fichiers Excel avec `openpyxl`

RÉSULTATS CLÉS

◆ OBSERVATION IMPORTANTE

Les fichiers d'admission couvrent **6 années académiques** avec des structures relativement homogènes. Cependant, les critères d'évaluation ont évolué entre 2020 et 2025, ce qui nécessitera une phase de normalisation des données.

Les données disponibles contiennent principalement:

1. **Informations académiques**: université d'origine, programme, GPA/notes
2. **Évaluations du comité**: scores par critère, décision finale, commentaires
3. **Métadonnées**: dates de candidature, round (1er/2ème), statut

DÉFIS ET OBSTACLES

⚠ BLOQUANT

Les données réelles des étudiants sont nécessaires pour avancer sur le prototype. L'obtention de ces données est soumise à l'accord du **Data Protection Officer (DPO)** de l'EPFL. En attendant cette autorisation, le développement est bloqué sur la partie analyse des dossiers.

- **Accès aux données**: en attente de l'accord du DPO pour obtenir les dossiers de candidature (même anonymisés)
- **Hétérogénéité des formats**: les fichiers Excel ne suivent pas un schéma strictement identique d'une année à l'autre
- **Choix du LLM local**: arbitrage entre performance et capacité à tourner sur les clusters HPC

SUIVI DES TÂCHES

✓ Inventaire des données d'admission MTE — fait

✓ Analyse de la structure des fichiers Excel — fait

✓ Recherche modèles open-source (Llama, Mistral, Qwen, Phi) — fait

✓ Demande d'accès HPC SCITAS — fait

✓ Mise en place du dépôt Git et environnement — fait

✗ Obtention des données via le DPO — bloqué

◯ Connexion et tests sur les clusters HPC — à faire

◯ Pipeline d'anonymisation des données — à faire

PLAN POUR LA SEMAINE PROCHAINE

Priorité haute

- Se connecter aux clusters HPC via VPN et valider l'environnement
- Relancer le DPO pour l'accès aux données de candidature
- Premiers tests d'inférence avec un modèle open-source sur le cluster

Priorité moyenne

- Avancer sur le pipeline d'anonymisation en utilisant des données synthétiques
- Définir l'architecture détaillée du système multi-agents