EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

S2 Rapport Hebdomadaire

26 février 2026

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Étudiant	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse

RÉSUMÉ DE LA SEMAINE

Réception des dossiers de candidature (volées 2020–2026). Transfert sur le cluster SCITAS et mise en place de l'environnement SSH. Extraction, inventaire et analyse exploratoire des dossiers étudiants. Conversion des guidelines d'admission en format exploitable pour le futur pipeline RAG.

DOSSIERS REÇUS	FICHIERS EXTRAITS	AVANCEMENT GLOBAL
2020–26	**~120**	**12%**
Toutes les volées MTE	PDFs (CV, relevés, lettres, ...)	Phase: Exploration des dossiers

Progression du projet 12%

TRAVAIL EFFECTUÉ

Réception et organisation des dossiers

Les dossiers de candidature contenant des données sensibles, le superviseur a contacté les responsables IT de l'EPFL (Carlos et Jean-François), sur recommandation de Nicolas Grandjean (AVP-E) et Chiara Tanteri (DPO), afin de s'assurer des bonnes pratiques pour l'hébergement et l'accès à ces données. Les directives de leur part sont en attente.

Les archives zip de l'ensemble des dossiers de candidature ont été reçues via SWITCHdrive pour toutes les années académiques de 2020 à 2026. Les étapes suivantes ont été réalisées :

- Téléchargement des archives depuis SWITCHdrive
- Décompression de l'ensemble des dossiers
- Transfert sur le cluster Izar (SCITAS) dans le répertoire `home`

- Suppression des fichiers de l'ordinateur personnel

L'ensemble du projet est hébergé sur le `home` du cluster Izar. Le travail s'effectue désormais intégralement dans un environnement SSH sur le cluster.

À titre d'exemple, les 11 dossiers de la volée MTE 2025–26 sont organisés comme suit :

```
data/raw/applications/dossiers/
├── kammoun/        (10 fichiers)
├── khribeche/      (4 fichiers)
├── kurbanzade/     (13 fichiers)
├── nana_davies/    (13 fichiers)
├── oh/             (13 fichiers)
├── papathanasiou/  (12 fichiers)
├── sarin/          (13 fichiers)
├── senger/         (5 fichiers)
├── shreevastava/   (15 fichiers)
├── vejayan/        (10 fichiers)
└── zhang/          (10 fichiers)
```

Le placement dans `data/raw/` suit la convention *cookiecutter-datascience* : les données brutes sont immuables et jamais modifiées, seul le dossier `data/processed/` contient les sorties dérivées.

Analyse exploratoire des dossiers (EDA)

Un notebook Marimo dédié (`notebooks/dossier_eda.py`) a été créé pour inventorier et visualiser le contenu des dossiers. L'analyse couvre :

- **Inventaire complet** : chaque fichier est catalogué avec son type de document, sa taille et son extension
- **Fichiers par candidat** : de 4 (khribeche) à 15 (shreevastava), avec une moyenne d'environ 11 fichiers
- **Types de documents** : 17 catégories identifiées (synthèse, lettre de motivation, CV, relevés de notes, lettres de recommandation, passeport, certificats linguistiques, résultats GRE, etc.)
- **Matrice de complétude** : vérification de la présence des 5 documents obligatoires (synthèse, motivation, CV, relevé de notes, pièce d'identité)
- **Documents optionnels** : couverture des lettres de recommandation, TOEFL/IELTS, GRE
- **Formats** : 100% des fichiers sont au format PDF

Conversion des guidelines d'admission

Le document interne de guidelines d'admission (`mte_admission_guidelines_2024-04-22.docx`) a été converti en Markdown structuré. Ce format permet :

- Un découpage naturel par sections pour le futur pipeline RAG
- Une lecture directe par les modèles de langage
- Un versionnement propre dans Git

Les guidelines définissent notamment :

- Les principes généraux de sélection (top candidates, diversité, anti-clusters)
- Les règles pour les doubles diplômes (officiels vs. « cachés »)
- Les seuils de GPA recommandés par pays et catégorie d'université (A/B/C/X)
- Les cas particuliers (Polytechnique Paris, ENS Lyon, HES, candidats chinois)

RÉSULTATS CLÉS

◆ STRUCTURE DES DOSSIERS

Les dossiers suivent une convention de nommage cohérente issue de la plateforme ISA : `N - Cand. Master <Type de document>_<ID>/<fichier>.pdf`. Cette structure permet une extraction automatique du type de document par expression régulière.

◆ COMPLÉTUDE VARIABLE

Certains dossiers sont très complets (13–15 fichiers avec recommandations, GRE, TOEFL) tandis que d'autres sont minimalistes (4–5 fichiers). Cette hétérogénéité devra être prise en compte par le système d'évaluation.

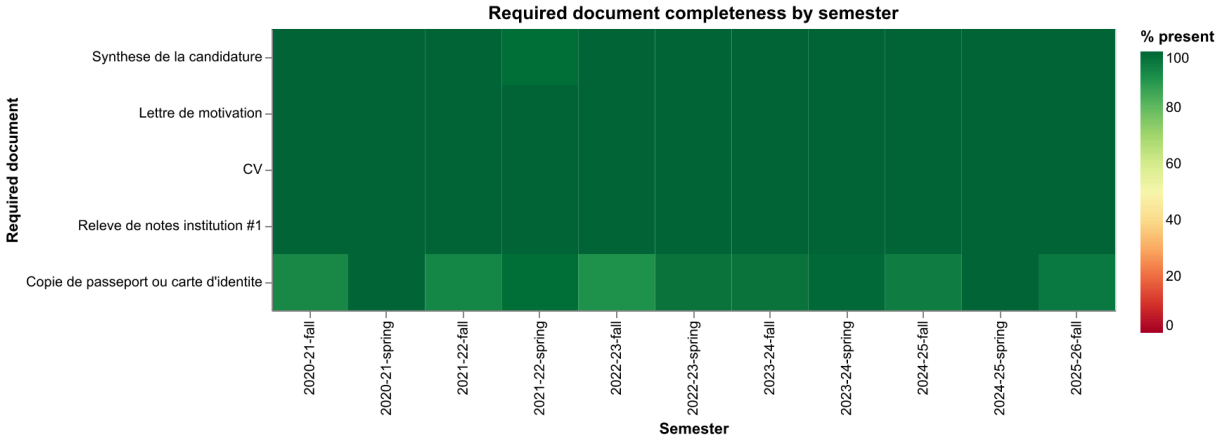


Fig. 1. – Matrice de complétude des documents obligatoires par semestre (2020–2026).

? QUESTION OUVERTE

Les dossiers incomplets (documents obligatoires manquants) font-ils l'objet d'un rejet automatique, ou sont-ils tout de même évalués ?

DÉFIS ET OBSTACLES

- **Extraction du texte des PDFs** : les fichiers sont des PDFs, certains pourraient être des scans (images) nécessitant de l'OCR plutôt qu'une simple extraction de texte
- **Données sensibles** : les dossiers contiennent des copies de passeport et des informations personnelles — le pipeline devra intégrer une couche d'anonymisation avant tout traitement par LLM
- **Seuils GPA par pays** : la table de seuils par pays et catégorie d'université (A/B/C/X) a été extraite des slides et intégrée dans le Markdown des guidelines

SUIVI DES TÂCHES

✓ Décompression et organisation des 11 dossiers — fait

- ✓ Notebook EDA dossiers (inventaire, complétude, visualisations) — fait
- ✓ Conversion des guidelines en Markdown (incl. seuils GPA) — fait
- ✓ EDA globale des données tabulaires (1 342 candidats) — fait
- ◯ Extraction de texte des PDFs — à faire
- ◯ Détection scan vs. texte natif (OCR nécessaire ?) — à faire
- ◔ Pipeline d'anonymisation des données sensibles — en cours
- ✓ Transfert des données et mise en place de l'environnement SSH sur SCITAS — fait

PLAN POUR LA SEMAINE PROCHAINE

Priorité haute

- Extraire le texte de tous les PDFs et identifier ceux nécessitant de l'OCR
- Commencer le pipeline de structuration : pour chaque candidat, produire un JSON normalisé avec les informations extraites de chaque document
- Vérifier l'exhaustivité des seuils GPA intégrés (pays manquants ?)

Priorité moyenne

- Premiers tests d'inférence LLM sur les clusters HPC SCITAS
- Définir le schéma Pydantic pour les données structurées d'un dossier candidat
- Prototyper le chunking des guidelines pour le pipeline RAG