EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

S3 Rapport Hebdomadaire

8 mars 2026

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Étudiant	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse

RÉSUMÉ DE LA SEMAINE

Pipeline d'anonymisation PII implémenté (Presidio + GLiNER) et testé sur un échantillon avec résultats concluants. Cluster SCITAS indisponible depuis vendredi : travail en local.

FAUX POSITIFS CORRIGÉS	TESTS UNITAIRES	AVANCEMENT GLOBAL
12+	108	25%
Allow-list, seuils, filtres	Tous passent	Phase: Anonymisation

Progression du projet 25%

TRAVAIL EFFECTUÉ

Pipeline d'anonymisation PII

Le pipeline repose sur **Presidio** comme orchestrateur avec **GLiNER** (`urchade/gliner_multi_pii-v1`, 500M params) comme backend NER zero-shot multilingue. Il détecte :

- **PII structurés** (regex) : emails, téléphones, URLs, numéros AVS/AHV, SCIPER
- **PII contextuels** (GLiNER) : noms, adresses, dates de naissance, organisations

Des recognizers personnalisés ont été ajoutés pour les numéros AVS (`756.XXXX.XXXX.XX`) et SCIPER (6 chiffres avec contexte).

Réduction des faux positifs

Les premiers tests révélaient de nombreux faux positifs (« I » → `<PERSON>`, « C++ » → `<PERSON>`, « EPFL » → `<PII>`, coupures de mots comme « Wit`<PERSON>` »). Trois modules correctifs ont été développés :

- **Allow-lists** : termes sûrs en 5 catégories (institutions, académique, pronoms, technique, activités) passés à Presidio
- **Seuils par entité** : seuils différenciés selon l'ambiguïté (0.4 pour EMAIL/PHONE, 0.6 pour PERSON, 0.65 pour NRP/organization)
- **Filtres post-analyse** : limites de mots, longueur minimale, mots courants, durées vs dates — appliqués séquentiellement après la détection

Test sur échantillon

Pipeline testé sur `test_tiny` (1 candidat, 2 documents).

◆ **AVANT / APRÈS**

Avant :
`<PERSON> am writing ... Wit<PERSON> an <PII> ... <PERSON> | Visual Basic`
Après : `I am writing ... With an ... C++ | Visual Basic`

Pronoms, EPFL, diplômes, termes techniques préservés. Vrais PII (noms, emails, téléphones) toujours anonymisés.

DÉFIS ET OBSTACLES

⚠ **CLUSTER SCITAS INDISPONIBLE**

SCITAS est hors service depuis vendredi après-midi. Le développement continue en local. La conversion PDF à grande échelle et l'inférence LLM nécessitent le retour du cluster.

- **Conversion PDF → Markdown** : 13 600 PDFs à convertir (texte natif + OCR pour les scans), bloqué par l'indisponibilité de SCITAS

SUIVI DES TÂCHES

✓	Pipeline Presidio + GLiNER fonctionnel	fait
✓	Recognizers personnalisés AVS/AHV et SCIPER	fait
✓	Allow-lists, seuils et filtres post-analyse	fait
✓	Tests unitaires (108 tests)	fait
✓	Test sur échantillon réel (test_tiny)	fait
✗	Conversion PDF → Markdown (13 600 fichiers)	bloqué

✕ Anonymisation à grande échelle **bloqué**

◯ Pipeline LLM pour le schéma de décision **à faire**

PLAN POUR LA SEMAINE PROCHAINE

Priorité haute

- Dès le retour de SCITAS : conversion PDF → Markdown puis anonymisation sur l'ensemble des fichiers
- Valider les résultats sur un échantillon plus large (50–100 dossiers)

Priorité moyenne

- Lier les dossiers anonymisés aux données structurées du Parquet (décisions du comité, GPA, université)
- Premiers tests d'évaluation LLM : guidelines en contexte + dossier candidat, comparer la décision du modèle avec celle du comité