EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

S4 Rapport Hebdomadaire

10 mars 2026

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Étudiant	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse

RÉSUMÉ DE LA SEMAINE

Suite au feedback du Prof. de Rassenfosse, l'anonymisation a été calibrée pour préserver les signaux utiles à la décision d'admission (année de naissance, localisation, langues, institutions) tout en continuant à masquer les vrais PII. Validé sur 6 documents (2 candidats, 3 types de documents).

TESTS UNITAIRES	ENTITÉS EXCLUES	AVANCEMENT GLOBAL
135	**4**	**30%**
Tous passent	LOCATION, NRP, ORG, organization	Phase : Anonymisation v2

Progression du projet **30%**

TRAVAIL EFFECTUÉ

Feedback Prof. de Rassenfosse

L'anonymisation de la semaine 3 était fonctionnelle mais **trop agressive** pour un usage en décision d'admission. Quatre points spécifiques ont été soulevés :

1. **Date de naissance** : l'âge est un critère de rejet, il faut garder l'année de naissance
2. **Localisation** : permet d'identifier l'expérience internationale
3. **Langues** : compétence importante à conserver
4. **Noms d'institutions** : signal important dans les lettres de référence et les CV

Calibrage de l'anonymisation

Trois mécanismes coordonnés ont été implémentés, chacun ciblant le bon point d'interception dans le pipeline :

1. Filtre d'exclusion d'entités (post-filtre)

Nouveau filtre `filter_excluded_entities()` placé en **première position** dans le pipeline de filtres. Il supprime les résultats dont le type d'entité est dans un ensemble configurable via la variable d'environnement `ANONYMIZER_EXCLUDED_ENTITIES`.

Pourquoi un post-filtre ? Retirer les types de `_ENTITY_PLACEHOLDER_MAP` ne suffit pas car Presidio les détecterait quand même. Retirer de `_GLINER_ENTITIES` n'affecterait que GLiNER, pas les recognizers Presidio intégrés. Le post-filtre agit comme un portail universel après tous les recognizers.

Entités exclues par défaut : `LOCATION`, `NRP`, `organization`, `ORGANIZATION`.

> ◆ **POINT TECHNIQUE**
>
> `organization` (minuscule) vient de GLiNER, `ORGANIZATION` (majuscule) vient du recognizer Presidio intégré. Les deux doivent être exclus pour éviter les faux positifs sur les noms d'institutions. Première version n'excluait que le minuscule — 26 faux positifs sur le Statement of Purpose.

2. Allow-list LANGUAGES

Même avec NRP exclu, des noms de langues comme « French » pouvaient être capturés comme `PERSON` par d'autres recognizers. Un `frozenset` de 75 langues naturelles a été ajouté comme 6e catégorie d'allow-list (défense en profondeur).

3. Opérateur DOB personnalisé

Classe `DobYearOperator` (sous-classe de `presidio_anonymizer.Operator`) qui extrait l'année à 4 chiffres du texte détecté et produit `<DOB_1995>` au lieu de `<DOB>`. Regex : `\\b((?:19|20)\\d{2})\\b`. Fallback vers `<DOB>` si aucune année trouvée. Appliqué uniquement aux entités `"date of birth"` (GLiNER) ; `DATE_TIME` (Presidio) reste `<DATE>`.

Validation sur échantillon élargi

Pipeline testé sur `test_anon` (2 candidats, 6 documents : CV, lettre de motivation, lettre de recommandation).

> ✓ **RÉSULTATS**
>
> **DOB** : `05/08/1984` → `<DOB_1984>` — année préservée
> **Locations** : Egypt, Saudi Arabia, Dubai, Switzerland, Lausanne, Beyrouth — toutes préservées
> **Langues** : Arabic (native), French (beginner), English — préservées
> **Institutions** : EPFL, UNESCO, Université Saint Joseph, USJ ESIB, British Council, INTERNATIONAL ADVANCED TECHNOLOGY — préservées
> **Vrais PII** : noms → `<PERSON>`, emails → `<EMAIL>`, téléphones → `<PHONE>`, adresses → `<ADDRESS>` — toujours anonymisés

Architecture du pipeline d'anonymisation

```
Texte brut
  │
  ▼
Presidio AnalyzerEngine (GLiNER + recognizers custom)
  │
  ├─ Allow-list (6 catégories : institutions, académique,
  │  pronoms, technique, activités, LANGUES)
  │
  ▼
Post-filtres (appliqués séquentiellement) :
  1. filter_excluded_entities  ← NOUVEAU (LOCATION, NRP, ORG)
  2. filter_by_entity_threshold
  3. filter_partial_words
  4. filter_by_length
  5. filter_common_words
  6. filter_duration_as_date
  │
  ▼
Presidio AnonymizerEngine
  ├─ DobYearOperator          ← NOUVEAU (date of birth → <DOB_YYYY>)
  └─ replace operator          (tous les autres types)
  │
  ▼
Texte anonymisé
```

DÉFIS ET OBSTACLES

⚠ **NON-DÉTERMINISME GLINER**

Le modèle GLiNER produit parfois des entités différentes entre deux exécutions sur le même texte. Observé : un span de texte détecté comme `EPFL_SCIPER` lors d'une exécution mais pas la suivante, alors qu'aucun nombre à 6 chiffres n'était présent. Le pipeline de filtres gère ces cas, mais cela implique une légère variabilité des résultats.

- **Extraction PDF lente sur CPU** : Docling met 25 min par PDF en local. La conversion à grande échelle nécessite SCITAS (GPU).
- **Docling instable sur certains scans** : crash sur une lettre de recommandation scannée (bug PIL/image de taille nulle)

SUIVI DES TÂCHES

✓ Filtre d'exclusion d'entités (LOCATION, NRP, ORG) — fait

✓ Allow-list LANGUAGES (75 langues) — fait

✓ Opérateur DOB personnalisé (<DOB_YYYY>) — fait

- ✓ Tests unitaires (135 tests, couverture ≥ 40%) — fait
- ✓ Validation sur 2 candidats (6 documents) — fait
- ✓ Documentation logique d'anonymisation — fait
- ✗ Conversion PDF → Markdown à grande échelle — bloqué
- ◯ Anonymisation corpus complet — à faire
- ◯ Pipeline LLM : évaluation vs décision comité — à faire

PLAN POUR LA SEMAINE PROCHAINE

Priorité haute

- Conversion PDF → Markdown sur SCITAS (GPU) pour les 13 600 fichiers
- Anonymisation à grande échelle et validation sur 50–100 dossiers
- Corriger les faux positifs résiduels (`AGE` sur « 5 years », `DATE_TIME` sur « fourth-year »)

Priorité moyenne

- Lier les dossiers anonymisés aux données structurées Parquet (décisions du comité, GPA, université)
- Premiers tests d'évaluation LLM : guidelines en contexte + dossier, comparer décision modèle vs comité