EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

S6 Rapport Hebdomadaire

24 mars 2026

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Étudiant	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse

RÉSUMÉ DE LA SEMAINE

Consolidation et durcissement du pipeline d'anonymisation suite à l'audit qualitatif de la semaine précédente : reconnaissance explicite des passeports, propagation systématique des noms entre documents d'un même dossier, hash SHA-256 des chemins (les noms de fichiers contenaient encore des PII). Refactorisation de la table de mapping (JSON → Parquet) pour absorber la prochaine cohorte. Stabilisation CI : tous les hooks ruff / ty passent propre sur la base. Conception du dashboard d'aide à la décision pour le comité (`docs/plans/2026-03-24-admission-dashboard-design.md`).

PRS MERGÉES	FAUX POSITIFS PII	LINT / TYPE
2	**−40%**	**0**
#6 anonymizer + #9 lint	Vs. mesure semaine 5	Erreurs sur `uv run poe lint`

Progression du projet **56%**

TRAVAIL EFFECTUÉ

Audit anonymizer : corrections (PR #6)

L'audit qualitatif de fin de semaine 5 (relecture manuelle de 30 dossiers anonymisés via le dashboard 3-panneaux) a remonté plusieurs défauts récurrents :

- **Numéros de passeport non détectés** : GLiNER ne reconnaît pas les formats nationaux (8 caractères alphanumériques pour la Suisse, 9 chiffres pour l'Inde, etc.).
- **Prénoms isolés non masqués** : le nom complet est détecté en page 1 du formulaire mais pas la mention isolée dans une recommandation (« I taught Maria during … »).

- **Métadonnées PDF** qui contenaient le nom complet et étaient copiées intactes lors de l'extraction de texte.
- **Noms de fichiers** (`Cand. Master Synthese de la candidature_<NOM>_<NUM>.pdf`) qui re-divulguaient l'identité dans l'arborescence anonymisée.

Corrections livrées :

1. **Passport recognizer** dédié dans `anonymizer/recognizers.py` : patterns regex par pays (CH, IN, FR, IT, plus de 20 nationalités observées dans les cohortes historiques), validés contre les faux positifs (numéros de cours, codes ECTS).
2. **Injection des noms de métadonnées** : avant d'invoquer GLiNER, on extrait les champs Author / Title du PDF et on les ajoute à une liste de termes à masquer dans tout le dossier.
3. **Hashing des chemins** (SHA-256, 12 premiers caractères) : `Cand. Master Synthese..._F1226945050` devient `00a9e4255a5b/`. La table de correspondance `path_mapping` est conservée hors du dossier anonymisé.

Refactor : Parquet path mapping

Le mapping `original_path → hashed_path` était stocké en JSON. Pour 1 342 candidats × 10 documents = 13 000+ entrées avec des champs longs (noms de fichiers, paths absolus, métadonnées), la lecture devenait lente côté dashboard. Refactor vers Parquet :

- Lecture 8× plus rapide (PyArrow vs `json.load`)
- Schéma typé qui empêche les régressions silencieuses
- Compression : 14 Mo JSON → 2.1 Mo Parquet
- API identique côté caller (`load_path_mapping()` retourne le même `dict`)

Stabilisation CI (PR #9)

`ruff check --select=ALL` remontait 90+ erreurs résiduelles sur la base élargie (anonymizer, dashboard, slurm scripts). Catégorisation et fix par lots :

- **N806** (variables non snake_case) : 12 occurrences dans `dashboard/app.py` (`PII_TYPES`, `BADGE_COLORS`) → renommées ou marquées comme constantes (`UPPER_CASE`).
- **SIM102** (collapsable nested if) : 8 occurrences dans `presidio_pipeline.py`.
- **ERA001** (commented-out code) : 15 blocs de TODO morts supprimés ou convertis en `# TODO(elie): ...`.
- **PLR2004** (magic values) : 30+ seuils déplacés vers des constantes nommées (`_GRADE_REGEX_MAX_LEN`, etc.).

Tous les hooks pre-commit (`ruff check`, `ruff format`, `ty check`, `uv lock --check`) passent désormais propre. Le workflow GitHub Actions est vert sur `main`.

Design : dashboard d'aide à la décision

Document `docs/plans/2026-03-24-admission-dashboard-design.md` finalisé avec le superviseur. Cible : faire évoluer le dossier viewer Streamlit en outil d'aide à la décision pour le comité.

> ▸ **VISION PRODUIT**
>
> Le comité voit une **table de candidats triable / filtrable** avec un résumé IA en 3 phrases par dossier. Cliquer ouvre un panneau de détail avec : analyse par agent, références cliquables vers les documents (PDF / texte / anonymisé), et un **chat** pour interroger le dossier.

Décisions structurantes :

- **Décision agent** affichée comme badge coloré : Admit (vert) / Reject (rouge) / Discuss (ambre) / Pending (gris).
- **Confidence** affichée en italique « Insufficient information » quand < 0.3 plutôt qu'un score à 2.
- **Trois onglets** dans le détail : Analyse agents (par défaut), Documents (avec inline links), Chat.
- Réutilisation maximale du dashboard 3-panneaux existant pour l'affichage des documents.

DÉFIS ET OBSTACLES

⚠ **FAUX POSITIFS RÉSIDUELS**

Le passport recognizer attrape parfois des codes de cours ressemblants (ex. « EE-330H » classé comme passeport US). Mitigé par un filtre post-detection qui exclut les tokens commençant par un préfixe institutionnel connu (`EE-`, `CS-`, `MATH-`, etc.).

- **Mapping JSON → Parquet** : la migration a temporairement cassé le dashboard pour les anciens runs. Un script `migrate_path_mapping.py` convertit les anciens JSON. Inclus dans la PR.
- **Performance GLiNER** : la propagation des noms double le temps d'inférence par dossier (2× passes). Acceptable pour une cohorte par semestre ; à monitorer si on passe au temps réel.

FICHIERS MODIFIÉS

◆ **RÉSUMÉ DES CHANGEMENTS**

18 fichiers, 1 200 lignes ajoutées / supprimées

Anonymizer (PR #6) :
`anonymizer/recognizers.py` — passport recognizers par pays
`anonymizer/presidio_pipeline.py` — métadonnées + propagation
`anonymizer/post_filters.py` — filtres préfixes institutionnels
`anonymizer/path_hashing.py` — SHA-256 path hash + table

Refactor :
`anonymizer/path_mapping.py` — JSON → Parquet (PyArrow)
`scripts/migrate_path_mapping.py` — migration one-shot

Lint / CI (PR #9) :
90 corrections ruff réparties sur 12 fichiers
`pyproject.toml` — pin Python 3.12 dans pre-commit

Design :
`docs/plans/2026-03-24-admission-dashboard-design.md` (130 lignes)

SUIVI DES TÂCHES

- ✓ Passport recognizer (regex multi-pays + filtre préfixes) — fait
- ✓ Métadonnées PDF injectées comme PII — fait
- ✓ Propagation des noms entre documents d'un dossier — fait
- ✓ Hash SHA-256 des chemins (no-PII filenames) — fait
- ✓ Refactor path_mapping JSON → Parquet — fait
- ✓ Script de migration one-shot path_mapping — fait
- ✓ Stabilisation lint (90+ erreurs ruff résolues) — fait
- ✓ Design doc dashboard d'aide à la décision — fait
- ◔ Design doc pipeline E2E + calibration — en cours
- ◯ Implémenter le runner d'évaluation (CLI) — à faire
- ◯ Calibration culturelle des lettres (zsearch + profils) — à faire

PLAN POUR LA SEMAINE PROCHAINE

Priorité haute

- Finaliser le design doc **E2E evaluation pipeline** : charger / enrichir les dossiers, ingérer les lettres historiques dans Zero Entropy, générer des profils de calibration par école via OpenRouter.
- Démarrer l'implémentation sur une branche dédiée (`feat/base-development`) : dossier loader, calibration ingest, evaluation runner CLI.
- Définir le format `PanelVerdict` final pour la persistance (JSON vs Parquet) et le contrat avec le dashboard.

Priorité moyenne

- Extracteur GPA cross-système (4.0 / 6.0 / 20 / 100 / lettres) : spec et premier prototype.
- Préparer les SLURM scripts pour le runner d'évaluation (mode trial 5 candidats / mode full).
- Maquettage de la table candidat du dashboard avec données factices (`mock_data.py`).