EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

S8 Rapport Hebdomadaire

19 avril 2026

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Étudiant	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse

RÉSUMÉ DE LA SEMAINE

Quatre modifications au pipeline d'évaluation suite à la réunion avec le second superviseur : pondération explicite du score composite (académique dominant), format pros/cons à puces, assignation de mineur par LLM, et débats pliables dans le dashboard. Un script de démo évalue 5 candidats (2 admis, 3 refusés) et compare avec les décisions du comité. Premier taux d'accord : 20% — le calibrage des prompts et des seuils de décision est en cours.

CANDIDATS ÉVALUÉS	ACCORD AGENT/COMITÉ	MINEURS EPFL
5	**20%**	**36**
2 admis, 3 refusés	1/5 (avant calibrage)	Registre complet 2025-26

Progression du projet **65%**

TRAVAIL EFFECTUÉ

Score composite pondéré

Le score composite était calculé par le LLM, sans contrôle. Il est maintenant déterministe, calculé en Python avec des poids fixes :

- **Académique** (25%) + **institution** (15%) + **référence** (15%) = 55% pour les critères primaires
- **Motivation** (5%) + **adéquation** (5%) + **risques** (5%) + **cohérence** (5%) = 20% pour les signaux secondaires
- **Confiance calibration** (10%) module la fiabilité des lettres

Le professeur a insisté : une lettre de motivation faible ne doit pas couler un candidat académiquement fort. Les poids traduisent cette consigne.

Format pros/cons à puces

Les justifications textuelles libres ont été remplacées par un format structuré `{"pros": [...], "cons": [...]}` à tous les niveaux :

- Nouveau modèle `DimensionJustification(pros, cons)` par dimension
- Nouveau modèle `VerdictSummary(pros, cons)` pour le verdict final
- Le dashboard affiche deux colonnes : vert (+) à gauche, rouge (-) à droite

Les membres du comité peuvent parcourir un candidat en quelques secondes au lieu de lire des paragraphes.

Assignation de mineur par LLM

Un cinquième agent (**Minor Advisor**) recommande les 3 mineurs EPFL les mieux adaptés au profil du candidat. Il s'exécute en parallèle avec les 4 évaluateurs pendant la Phase 1.

- `models/minor.py` : registre des 36 mineurs EPFL 2025-26 avec codes section, types (disciplinaire/interdisciplinaire) et contacts
- `agents/minor_advisor.py` : classification LLM avec la liste des mineurs injectée comme contexte structuré
- Règle par défaut : Industrial Engineering → Systems Engineering quand le modèle hésite
- Le dashboard affiche un badge bleu « Minor: X » sur chaque carte candidat et des cartes de recommandation classées dans l'onglet d'analyse

Débats pliables dans le dashboard

Les transcriptions de débat entre agents étaient affichées en bloc, forçant un défilement long. Elles sont maintenant dans un `st.expander()` fermé par défaut. Un clic suffit pour les consulter.

Script de démo (`scripts/demo_eval.py`)

Un script évalue 5 candidats pré-sélectionnés et compare les résultats avec les décisions du comité :

Candidat	École	Comité	Agent
Banasevic	UC San Diego	Accepté	Waitlist
Polydorou	NTUA Athènes	Accepté	Waitlist
Atamny	TU München	Refusé	Reject
Boukhabrine	McGill	Refusé	Waitlist
Fukuno	Kyoto	Refusé	Waitlist

Accord : 1/5 (20%). Le système met presque tout le monde en waitlist. Trois problèmes identifiés et corrigés cette semaine :

1. Les justifications des évaluateurs (format `dict[str, str]`) étaient silencieusement rejetées par Pydantic après le changement de type vers `DimensionJustification`. Le Chair recevait des scorecards vides.
2. `asyncio.gather(return_exceptions=True)` avalait les erreurs de validation. Les évaluateurs et le Minor Advisor sont maintenant séparés : les évaluateurs échouent bruyamment, le Minor Advisor est best-effort.

3. Les agents traitaient les artefacts OCR (caractères illisibles, GPA à zéro, champs vides) comme des incohérences réelles. Un caveat OCR a été ajouté à tous les prompts.

Calibrage des prompts (en cours)

Corrections appliquées après analyse des 5 premiers verdicts :

- **Ancres de scoring** pour l'évaluateur académique : GPA top 5% → score 9-10, top 25% → 7-8, sous la médiane → 3-5
- **Seuils de décision** pour le Chair : `academic >= 7` et `institution >= 6` → accept ; `academic <= 4` → reject ; waitlist réservé aux cas limites
- **Caveat OCR** dans tous les agents : ne pas pénaliser les candidats pour du bruit d'extraction PDF
- **Devil's Advocate** recentré sur les risques substantiels (fraude, contradictions entre documents) plutôt que les erreurs de forme

DÉFIS ET OBSTACLES

⚠ TAUX D'ACCORD FAIBLE

20% d'accord avec le comité. Le système est trop indécis : 4 candidats sur 5 reçoivent un « waitlist ». Le calibrage des seuils et des poids est la priorité immédiate.

- **Scorecards vides** : le bug `return_exceptions=True` a masqué des erreurs de validation pendant toute la première série de tests. Les verdicts reposaient uniquement sur le Chair sans input des évaluateurs.
- **Motivation trop pénalisante** : une lettre de motivation générique faisait chuter le composite d'un candidat à 9.02/10 de GPA vers un « waitlist ».
- **Données manquantes du fichier interne** : le document `Internal guidelines for master applications` contient des seuils GPA par pays et des catégories d'universités (A/B/C/X) qui ne sont pas encore encodés dans les prompts.

FICHIERS MODIFIÉS

◆ RÉSUMÉ DES CHANGEMENTS

10 fichiers créés ou modifiés, 900 lignes ajoutées

Nouveaux fichiers :
`models/minor.py` — 36 mineurs EPFL avec codes section (240 lignes)
`agents/minor_advisor.py` — classification LLM de mineur (130 lignes)
`scripts/demo_eval.py` — évaluation de 5 candidats (190 lignes)

Fichiers modifiés :
`agents/chair.py` — poids, `compute_composite()`, pros/cons
`agents/prompts.py` — ancres de scoring, seuils, caveat OCR
`agents/evaluators.py` — parsing `DimensionJustification`
`agents/orchestrator.py` — 5 tâches parallèles, gather séparé

`models/evaluation.py` — `DimensionJustification`, `VerdictSummary`, `MinorRecommendation`
`dashboard/review.py` — colonnes pros/cons, débats pliables, badge mineur
`dashboard/verdict_loader.py` — parsing justifications structurées

SUIVI DES TÂCHES

✓	Score composite pondéré (Python, poids fixes)	fait
✓	Format pros/cons structuré (modèles + prompts + dashboard)	fait
✓	Registre des 36 mineurs EPFL 2025-26	fait
✓	Minor Advisor agent (LLM + parallèle Phase 1)	fait
✓	Débats pliables dans le dashboard	fait
✓	Script demo_eval.py (5 candidats)	fait
✓	Fix bug scorecards vides (return_exceptions)	fait
✓	Ancres de scoring + seuils de décision	fait
✓	Caveat OCR dans tous les prompts	fait
◯	Encoder les seuils GPA par pays (guidelines internes)	à faire
◯	Encoder les catégories d'universités A/B/C/X	à faire
◯	Évaluer sur 20-50 candidats pour mesurer l'accord	à faire

PLAN POUR LA SEMAINE PROCHAINE

Priorité haute

- Relancer le demo après calibrage et mesurer le taux d'accord sur les 5 candidats. Objectif : >= 60%.
- Encoder les seuils GPA par pays et les catégories d'universités (A/B/C/X) du document « Internal guidelines for master applications » dans les prompts des agents.
- Étendre l'évaluation à 20-50 candidats pour obtenir un taux d'accord statistiquement significatif.

Priorité moyenne

- Traitement léger des candidats EPFL internes (réduire le poids de la qualité institutionnelle et des lettres de recommandation).
- Ajouter le mapping bachelor → mineur comme prior pour le Minor Advisor (au-delà de la règle Industrial Engineering → Systems Engineering).

- Explorer la distribution des scores par dimension pour détecter les agents trop conservateurs ou trop généreux.