EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

S9 Rapport Hebdomadaire

26 avril 2026

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Étudiant	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse

RÉSUMÉ DE LA SEMAINE

Réception des 119 dossiers de la cohorte 2025–26 (round 1). Pas de fichier Excel cette année : les informations candidat sont extraites directement des PDF « Synthèse de la candidature » via PyMuPDF. Un parseur bilingue (FR/EN), un batch builder, et un dashboard Streamlit de visualisation de cohorte ont été développés. Enrichissement des prompts évaluateurs avec le seuil GPA et la catégorie institutionnelle du SPE. Préparation du pipeline d'anonymisation pour la nouvelle cohorte.

CANDIDATS PARSÉS	PAYS D'ORIGINE	RÉPARTITION
119/119	**28**	**78M / 41F**
0 échec, FR + EN	Inde 15, Italie 12, Turquie 12	34% femmes

Progression du projet **72%**

TRAVAIL EFFECTUÉ

Parseur de Synthèse PDF (`synthese_parser.py`)

Le fichier Excel du comité n'est pas disponible cette année. Les données structurées sont extraites directement depuis le PDF « Synthèse de la candidature » présent dans chaque dossier.

Le formulaire EPFL existe en deux langues (français et anglais) avec des labels différents et une mise en page décalée (section études en page 3 en FR, page 2 en EN). Le parseur gère les deux variantes :

- **Page 1** : nom, prénoms, sexe, nationalité, numéro de candidature

- **Page études** (détection dynamique) : institution, pays, domaine, niveau d'étude, GPA, barème maximal
- Extraction par recherche de labels dans le texte brut PyMuPDF (pas de dépendance OCR, pas de LLM)
- Labels configurés dans un dictionnaire bilingue `_LABELS` avec gestion des lignes de continuation (e.g. « Prénoms (tels qu'indiqués sur papiers d'identité) »)

Batch builder (`cohort_builder.py`)

Script batch qui itère les 119 dossiers, localise le PDF Synthèse, appelle le parseur, et produit un fichier JSON consolidé :

- `data/processed/cohort_2025-26-fall.json` : 119 enregistrements
- Taux de succès : 100% (0 échec, 0 champ vide critique)
- Exécution en 1.5 secondes pour les 119 dossiers
- CLI : `uv run poe build-cohort`

Dashboard cohorte (`dashboard/cohort.py`)

Interface Streamlit pour le comité de lecture, accessible sans Excel :

- **Filtres latéraux** : recherche texte (nom, école), pays, genre, niveau d'étude, plage GPA normalisée (0–4)
- **Tri** : par nom, GPA, pays, institution
- **Métriques** : total, répartition genre, nombre de pays, nombre d'institutions, GPA moyen normalisé
- **Cartes candidat dépliables** : toutes les données extraites, nombre de fichiers dans le dossier
- Normalisation GPA : conversion automatique vers une échelle 0–4 (exclusion des barèmes allemands inversés)
- CLI : `uv run poe cohort` (port 8504)

Enrichissement des prompts évaluateurs

Le seuil GPA de la fiche SPE et la catégorie institutionnelle (A/B/C/X) sont désormais injectés dans le contexte de chaque évaluateur (`run_evaluation.py`). Cela permet aux agents de calibrer leur scoring par rapport aux attentes du comité.

Dashboard universités (`dashboard/universities.py`)

Nouveau dashboard pour visualiser et éditer les profils d'universités (tier A/B/C/X, statistiques historiques, notes du comité). Les overrides du comité sont sauvegardés en YAML.

Curriculum scraper et matcher

Scraper du catalogue EPFL pour les cursus bachelor et master, avec un matcher de curriculum par similarité pour le Minor Advisor. Design documenté dans `docs/plans/2026-04-20-curriculum-scraper-design.md`.

DÉFIS ET OBSTACLES

⚠ **DOSSIERS INCOMPLETS**

119 dossiers extraits sur les 220 attendus. Les 119 restants sont encore sous forme de fichiers ZIP non décompressés. En attente de la livraison complète pour traiter l'ensemble de la cohorte.

- **Labels de formulaire multilingues** : le formulaire EPFL peut être en français ou en anglais. Les labels de champs diffèrent et la section « Études » n'est pas sur la même page. Résolu par une détection dynamique de la page et un dictionnaire bilingue.
- **Champs GPA hétérogènes** : les candidats saisissent le GPA sous des formes variées (« 3.21 until the 10th Semester », « 7,75 », « 1.9/1.0 »). La normalisation best-effort fonctionne pour 90% des cas mais les barèmes allemands inversés sont exclus.
- **Pas de fichier Excel** : contrairement aux années précédentes, le comité ne dispose pas de fichier Excel pré-rempli. Le dashboard cohorte remplace ce workflow.

FICHIERS MODIFIÉS

◆ RÉSUMÉ DES CHANGEMENTS

8+ fichiers créés ou modifiés, 700 lignes ajoutées

Nouveaux fichiers :
`extraction/synthese_parser.py` — parseur bilingue FR/EN (200 lignes)
`extraction/cohort_builder.py` — batch processing 119 dossiers (120 lignes)
`dashboard/cohort.py` — dashboard cohorte Streamlit (320 lignes)
`dashboard/universities.py` — dashboard profils universités (230 lignes)
`curriculum/` — scraper et matcher de curriculum EPFL

Fichiers modifiés :
`agents/run_evaluation.py` — injection seuil GPA et catégorie SPE
`agents/orchestrator.py` — Minor Advisor best-effort séparé
`pyproject.toml` — tâches poe `cohort`, `build-cohort`, `universities`

SUIVI DES TÂCHES

✓	Parseur Synthèse PDF bilingue (FR + EN)	fait
✓	Batch builder → cohort JSON (119/119)	fait
✓	Dashboard cohorte Streamlit (filtres, tri, cartes)	fait
✓	Dashboard profils universités (tier, historique, overrides)	fait
✓	Injection seuil GPA + catégorie SPE dans évaluateurs	fait
✓	Curriculum scraper EPFL (bachelor + master)	fait
✓	Curriculum matcher pour Minor Advisor	fait

- ✓ Design doc scraper curriculum — fait
- ◯ Décompresser les 119 ZIP restants — à faire
- ◯ Anonymiser la cohorte 2025-26 — à faire
- ◯ Évaluer la cohorte complète avec le pipeline agent — à faire

PLAN POUR LA SEMAINE PROCHAINE

Priorité haute

- Recevoir et décompresser les dossiers manquants (objectif : 220+ candidats).
- Lancer le pipeline d'anonymisation sur la cohorte 2025–26 : `normalize-files` → `strip-passports` → `extract-text` → `anonymize`.
- Évaluer un premier lot de 20–30 candidats avec le pipeline agent et mesurer le taux d'accord avec le comité.

Priorité moyenne

- Améliorer le parseur GPA pour gérer les cas limites (barèmes inversés allemands, pourcentages, GPA textuels).
- Ajouter l'export CSV/Excel depuis le dashboard cohorte pour le comité qui préfère travailler hors ligne.
- Intégrer le curriculum matcher dans le Minor Advisor pour des recommandations basées sur le contenu des cours.