EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

S12 Rapport Hebdomadaire

16 mai 2026

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Étudiant	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse

RÉSUMÉ DE LA SEMAINE

Test de reproductibilité du pipeline d'évaluation : 5 exécutions indépendantes de la cohorte complète Spring 2025-26 (128 candidats) avec le modèle `google/gemini-3-flash-preview` via OpenRouter. L'objectif : mesurer la **variance entre runs** pour décider si le système est suffisamment fiable pour aider le comité (et identifier les dossiers borderline qui nécessitent une vraie décision humaine). **Résultat principal** : la distribution agrégée accept/reject/waitlist est extrêmement stable (40-43 admis sur 128, dans la cible comité 40-50). **76.6%** des candidats reçoivent la même décision dans les 5 runs ; les **30 flippers** sont presque tous sur la frontière waitlist. L'invariant déterministe pour les EPFL-internes (mapping mineur) tient à 100%.

RUNS COMPLETS	STABILITÉ DÉCISION	Σ ADMIS (RANGE)
5/5	**76.6%**	**39–43**
128 candidats × 5 = 640	98/128 décision identique × 5	Cible comité : 40–50

Progression du projet 87%

TRAVAIL EFFECTUÉ

Pourquoi tester la variance ?

Avant de présenter les verdicts au comité, il faut répondre à deux questions que les superviseurs (et le comité) vont poser :

1. **Le système est-il déterministe ?** Si on relance le pipeline sur la même cohorte, obtient-on la même réponse, ou est-ce qu'un candidat est tantôt admis tantôt refusé ?

2. **Quels sont les dossiers borderline ?** Là où le système hésite, c'est précisément là où la délibération humaine apporte de la valeur — on doit pouvoir les identifier sans les noyer dans la masse.

Le LLM n'étant pas déterministe par construction (température, échantillonnage), seule une mesure empirique répond. **5 exécutions indépendantes** est un compromis statistiquement utile et abordable en coût (12 USD OpenRouter, 85 minutes de wall-clock).

Méthodologie

- **Cohorte** : 128 candidats Spring 2025-26 (anonymisés).
- **Modèle** : `google/gemini-3-flash-preview` via OpenRouter (cheap, fast, c'est le modèle de production actuel).
- **Pipeline** : pipeline complet déployé en semaine 11 (gate GPA, profils EPFL-interne / externe, mapping mineur déterministe, fallback profil université).
- **5 runs** indépendants, sortie dans `data/processed/runs/run01..05/`.
- **Métriques calculées** via `scripts/cohort_variance_stats.py` :
  1. Stabilité de décision par candidat (mêmes verdicts dans les 5 runs ?)
  2. Liste des **flippers** (au moins une décision différente)
  3. Variance du score composite par candidat (mean / stdev / range)
  4. Variance par dimension (laquelle des 8 est la plus / moins stable)
  5. Invariance déterministe pour les EPFL-internes (mineur identique dans les 5 runs ?)
  6. Distribution agrégée accept/reject/waitlist par run

Résultat 1 — Distribution agrégée stable

Le nombre de candidats admis varie peu d'un run à l'autre :

Run	Accept	Reject	Waitlist	Total
run01	40	66	22	128
run02	39	67	22	128
run03	41	67	20	128
run04	39	67	22	128
run05	43	67	18	128

> ✓ **LECTURE COMITÉ**
>
> Le comité admet typiquement 40–50 candidats par cohorte. Tous les runs tombent dans (ou juste sous) cette fourchette. La règle de seuil composite ajoutée en semaine 11 (PR #18) ramène le taux d'admission de l'ancien 80/128 à 39–43/128.

Résultat 2 — 76.6% de stabilité par candidat

98 candidats sur 128 (76.6%) ont reçu exactement la même décision (accept / reject / waitlist) dans les 5 runs. **30 candidats** ont vu leur décision changer au moins une fois entre runs. Tous les flippers sont concentrés sur la frontière : transitions **waitlist ↔ accept** ou **waitlist ↔ reject**. Aucun cas de **accept ↔ reject** direct, ce qui est rassurant : le système ne fait pas de revirement complet.

Candidat (5 premiers flippers)	r01	r02	r03	r04	r05	Mode
`07fc9d7a9c95`	accept	waitlist	accept	accept	accept	accept
`0f817ee10abe`	reject	waitlist	reject	waitlist	waitlist	waitlist
`14bbfb46cb71`	reject	waitlist	reject	reject	reject	reject
`197a4a37be28`	reject	reject	waitlist	waitlist	reject	reject
`26ae784d194a`	reject	reject	waitlist	reject	reject	reject

Recommandation pratique : pour la production, agréger les 5 runs par **vote majoritaire** (mode) donnerait une décision défendable et plus stable que n'importe quel run individuel. La colonne Mode ci-dessus montre le résultat de ce vote.

Résultat 3 — Score composite très stable

- **Stdev moyen par candidat** : **0.175** (sur une échelle 1–10).
- **Stdev maximum** : **0.628** (un seul candidat borderline avec un range de 1.55 entre runs).
- 90% des candidats restent dans une fenêtre de ±0.2 autour de leur moyenne.

Résultat 4 — Variance par dimension

Dimension	Stdev moyen
`motivation_clarity`	0.053
`institution_quality`	0.129
`calibration_confidence`	0.132
`program_fit`	0.194
`reference_quality`	0.248
`academic_strength`	0.293
`consistency`	0.380
`risk_flags`	0.467

- **La plus stable** : `motivation_clarity` (0.053). Le prompt produit un signal très net.
- **La moins stable** : `risk_flags` (0.467). C'est la dimension Devil's Advocate, par construction interprétative et contradictoire. Variance attendue.
- `academic_strength` à 0.293 est plus haut qu'on souhaiterait : le Chair pondère cette dimension à 30–45% du composite. À surveiller.

Résultat 5 — Invariance déterministe EPFL : 100%

Pour les **vrais** candidats EPFL-internes (28 dans la cohorte Spring 2025-26), le mineur recommandé est **identique dans les 5 runs** à chaque fois. Le court-circuit déterministe de PR #18 fonctionne comme prévu.

> **i NOTE SUR LA HEURISTIQUE DE DÉTECTION**
>
> Le script de stats détecte les EPFL-internes en regardant si le `primary_minor` apparaît dans la table déterministe. Cette heuristique sur-classifie : 104 candidats au lieu des 28 réels, car le LLM advisor recommande parfois les mêmes noms de mineur pour des candidats externes. Sur les 7 « violations » remontées par le script, **aucune ne correspond à un vrai EPFL-interne** — ce sont

toutes des fluctuations du LLM advisor sur des dossiers externes ou des entrées vides quand l'advisor a échoué (best-effort).

DÉFIS ET OBSTACLES

⚠ **30 FLIPPERS À EXPLIQUER**

76.6% de stabilité signifie que 24% des dossiers individuels ont au moins une décision divergente. Pour le comité, cela veut dire que 30 candidats par cohorte sont « instables » et méritent une revue humaine. Identifier et flagger systématiquement ces cas dans le dashboard est la priorité de la semaine 13.

- **Coût et temps** : 5 runs × 128 candidats = 640 évaluations complètes, 12 USD et 85 minutes wall-clock. Acceptable comme test ponctuel ; à automatiser comme job hebdomadaire si on veut monitorer la stabilité dans le temps.
- **Heuristique de détection EPFL-interne** dans le script de stats est imparfaite (sur-classifie). Pour résoudre proprement, il faudrait stocker le flag `is_epfl_internal` dans le verdict JSON et le re-lire ; à faire en semaine 13.

FICHIERS MODIFIÉS

◆ **RÉSUMÉ DES CHANGEMENTS**

Nouveaux fichiers :
`scripts/cohort_variance_stats.py` — script de variance (260 l.)
`reports/cohort-variance-2026-05-09.md` — rapport stats détaillé
`reports/semaine-12.typ` — ce document

Données produites (gitignorées) :
`data/processed/runs/run01..05/` — 640 verdicts JSON
`data/processed/evaluations_baseline_pre_5x_run_2026-05-09/` — snapshot avant les 5 runs

Aucun fichier de production modifié. Le test de variance n'a nécessité aucun changement de code.

SUIVI DES TÂCHES

- ✓ Snapshot baseline (128 verdicts) avant relance — fait
- ✓ Smoke-test 1 candidat (validation pipeline) — fait
- ✓ Lancer 5 runs séquentiels en background (85 min) — fait

- ✓ Surveiller log pour erreurs / credits OpenRouter — fait
- ✓ Script `cohort_variance_stats.py` (8 dimensions analysées) — fait
- ✓ Rapport variance Markdown détaillé — fait
- ✓ Rapport hebdomadaire S12 (ce document) — fait
- ◯ Stocker `is_epfl_internal` dans le verdict JSON — à faire
- ◯ Flagger les 30 flippers dans le dashboard React — à faire
- ◯ Mode "vote majoritaire de N" comme option de production — à faire

PLAN POUR LA SEMAINE PROCHAINE

Priorité haute

- **Surfacer les flippers dans le dashboard** : nouveau champ `stability` (% des runs en accord) sur chaque candidat, avec badge orange « unstable » pour les 30 cas borderline. Permet au comité de prioriser sa relecture.
- **Persister `is_epfl_internal`** dans `PanelVerdict` pour rendre l'audit (et les tests d'invariance) propres sans heuristique.
- **Voter par majorité de N** : ajouter une option `--ensemble N` dans le runner qui exécute N fois et retourne le mode. Pour les flippers, le mode est plus stable que n'importe quel run individuel.

Priorité moyenne

- Audit qualitatif des 30 flippers avec le superviseur : sont-ce des cas où le comité hésite aussi (signal correct), ou des cas où le système rate quelque chose de clair (signal de calibration manquante) ?
- Étendre le test de variance à Fall 2025-26 quand cette cohorte sera anonymisée et matchée aux décisions du comité.
- Comparer la stabilité avec d'autres modèles (Sonnet 4.6, Haiku 4.5) pour quantifier le coût/bénéfice du choix de modèle.