EPFL ÉCOLE POLYTECHNIQUE FÉDÉRALE DE LAUSANNE
Management of Technology and Entrepreneurship (MTE)

S13 Rapport Hebdomadaire

23 mai 2026

Projet	Système Multi-Agents pour l'Aide à la Décision en Admission
Étudiant	Elie Bruno
Superviseur	Prof. Gaétan de Rassenfosse

RÉSUMÉ DE LA SEMAINE

Audit comparé comité vs système sur la cohorte Spring 2025-26 (5 runs agrégés par vote majoritaire). 47 désaccords sur 128 candidats, dont 19 cas où le système accepte un dossier que le comité refuse (universités internationales fortes) et 9 cas où le système refuse un dossier que le comité accepte (presque tous EPFL-internes en transition de section). Deux itérations de prompt sur le bloc EPFL-interne ont fait passer l'accord avec le comité de 14/28 à 19/28 pour cette sous-cohorte. Les 5 cas restants ont une moyenne algèbre+analyse entre 4.0 et 4.5 : Maillard, Hegi, Croisier, Gruber, Kvedarauskaite. Le système les refuse car ils sont sous le seuil 4.5 codé en dur ; le comité les a admis après examen détaillé. Email à Geraldine pour clarifier la règle officielle ; sa réponse arrivera en semaine 14.

DÉSACCORDS COMITÉ	EPFL-INTERNES	SCRIPTS D'ANALYSE
47/128	**14 → 19 / 28**	**5**
36.7% sur la cohorte entière	Accord après 2 itérations prompt	compare, rerun, before/after, back-fill

Progression du projet **90%**

TRAVAIL EFFECTUÉ

Audit comité vs système

Le plan de semaine 12 demandait un audit qualitatif des dossiers où agent et comité divergent. J'ai écrit `scripts/compare_committee_vs_runs.py` pour produire une matrice de confusion à partir des 5 runs agrégés par vote majoritaire. Le résultat sur Spring 2025-26 :

Comité \ Système	accept	waitlist	reject	total
accept	22	10	9	41
waitlist	0	0	0	0
reject	19	9	59	87

Le comité n'utilise jamais la catégorie waitlist en sortie (toutes les hésitations sont arbitrées en réunion), donc les colonnes waitlist du système correspondent à des cas que le comité a tranchés dans un sens ou l'autre. **L'accord brut sort à 81/128 (63.3%).**

Quatre types de désaccord à isoler :

◆ TYPES DE DÉSACCORD

Type A. Comité refuse, système accepte (19 cas). Universités internationales reconnues : NUS, Bocconi, RWTH Aachen, Erasmus Rotterdam, Duke Kunshan, KCL. Le score composite moyen sur ces 19 cas est 8.5. Le comité a vu autre chose dans le dossier (lettres faibles, parcours discontinu, manque de fit MTE) que le système n'a pas capté. À auditer avec le superviseur.

Type B. Comité accepte, système refuse (9 cas). Composite moyen 6.7. Sept des neuf sont EPFL-internes (Maillard, Hegi, Croisier, Gruber, Kvedarauskaite, Nguyen, Holtz). Un Polytechnico Torino, un Ouzbek pour les deux autres. La cause racine pour les EPFL-internes est le seuil 4.5 sur la moyenne algèbre+analyse.

Type C. Comité accepte, système waitlist (10 cas). Huit sont EPFL-internes avec composite entre 7.4 et 8.0. Cas frontière où la règle de seuil composite hésite.

Type D. Comité refuse, système waitlist (9 cas). Universités borderline, composite 7.4 à 8.1. Le système hésite, le comité tranche reject.

Focus sur les EPFL-internes

La cohorte Spring 2025-26 contient 28 EPFL-internes. Le comité en a admis 27 et refusé 1. Le système, dans son état semaine 12, n'était d'accord que sur 14/28 (50%). Les autres se décomposaient en :

- 8 reject erronés (sept cas Type B + un autre)
- 7 waitlist erronés (cas Type C)

J'ai isolé cette sous-cohorte avec `scripts/rerun_epfl_internals.py` pour itérer rapidement sans relancer les 128 candidats à chaque essai.

Itération 1 du prompt EPFL-interne

Hypothèse de départ : le système applique le seuil EPFL par défaut (4.5/6) alors que les section-switchers ont droit au seuil abaissé (4.0/6). Le prompt évoquait cette exception mais sans la flécher explicitement vers les candidats MTE.

Modification : j'ai ajouté un paragraphe qui dit que **tout candidat EPFL-interne en MTE est par construction un section-switcher** (il n'existe pas de bachelor MTE), donc le seuil 4.0 s'applique.

Résultat sur la sous-cohorte de 28 :

Run	Accept	Reject	Waitlist

Comité	27	1	0
Avant fix 1 (mode 5 runs)	13	8	7
Après fix 1 (run unique)	15	7	6

Accord avec le comité : 14/28 → 15/28 (54%). Trois cas flippés vers accept (Ta, Tirot, Décréau) ; deux régressions (Biersohn classé en waitlist au lieu de reject, Gousset en waitlist au lieu d'accept).

Bilan mitigé. Le prompt change la décision sur les bords mais ne dégage pas le bloc Maillard + Hegi + Croisier + Gruber

1. Kvedarauskaite qui reste en reject.

Itération 2 du prompt EPFL-interne

Inspection des composites : les cinq cas refusés ont un composite 6.34 à 7.45, juste sous le seuil reject_floor de la semaine 11. L'Academic Evaluator clampe leur `academic_strength` à 5/10 parce que le verdict GPA est BELOW (moyenne algèbre+analyse 4.0-4.5 contre seuil 4.5).

Modification 2 : interdiction explicite dans le prompt de citer « 4.33 sous le standard de 4.5 » comme contre-argument pour un candidat MTE, et rappel que le standard MTE est 4.0/6.

Résultat sur la sous-cohorte de 28 :

Run	**Accept**	**Reject**	**Waitlist**
Comité	27	1	0
Avant fix 2 (mode 5 runs)	15	5	8
Après fix 2 (run unique)	19	4	5

Accord avec le comité : 15/28 → 19/28 (68%). Quatre flips vers accept (Jariod, Cunningham, Gousset, Tekaya), zéro régression.

Les huit cas restants en désaccord :

Candidat	**Comité**	**Système**	**Composite**
Maillard Etienne	accept	waitlist	7.60
Hegi Sébastien	accept	waitlist	7.90
Croisier Noé	accept	waitlist	7.92
Haenni Clement	accept	waitlist	7.75
Kvedarauskaite Ieva	accept	reject	7.44
Gruber Max	accept	reject	7.31
Nguyen Thi Thu Tra	accept	reject	7.20
Holtz Sophie	accept	reject	7.17

Les quatre en reject ont une moyenne algèbre+analyse strictement sous 4.5. Le hard-reject du gate GPA tire la décision malgré la hausse du composite. Les quatre en waitlist sont entre 4.0 et 4.5 exact : le clamp à 5 du score Academic les pénalise mais sans déclencher le reject hard.

Communication avec le superviseur

J'ai écrit à Geraldine pour clarifier la règle officielle. Question posée : **le seuil 4.5 sur algèbre+analyse est-il un hard floor, ou une zone d'examen détaillé ?** Le cas Maillard suggère que le comité applique une règle plus fine que le seuil binaire ; il faut savoir laquelle avant de la coder.

Backfill des recommandations de mineur

Le pipeline ajouté en semaine 11 calcule un `MinorRecommendation` pour les EPFL-internes via mapping déterministe. Les 5 runs de semaine 12 datent d'avant ce calcul ; les verdicts JSON n'ont pas le champ rempli. `scripts/backfill_minor_recs.py` parcourt les verdicts existants, identifie les EPFL-internes, applique le mapping bachelor → mineurs, et patche les fichiers en place. Évite de relancer 640 évaluations LLM (économie : 12 USD et 85 minutes).

Comparaison before/after automatisée

`scripts/before_after_epfl.py` aligne deux jeux de verdicts JSON (avant et après une modification) sur la même sous-cohorte et produit le tableau before/after vu plus haut. Utilisé pour les deux itérations de prompt. Réutilisable pour toute modification future qui doit être mesurée.

DÉFIS ET OBSTACLES

⚠ LE MUR DU SEUIL 4.5

Cinq cas EPFL-internes restent en désaccord après deux itérations de prompt parce que leur moyenne algèbre+analyse est sous 4.5. La règle codée en dur (seuil unique 4.0 pour les section-switchers) force soit un reject, soit un clamp d'academic_strength qui tire le composite sous le floor 7.0. Le comité, lui, regarde le détail des notes (Maillard : 3.75 Analyse I mais 5.25 Analyse II) avant de trancher. Le système n'a pas ce levier ; il faut une règle à bandes, pas un seuil binaire.

- **Cohérence inter-runs** : la variance individuelle reste sous 0.3 de stdev sur le composite (mesuré en semaine 12), donc les changements de prompt produisent un signal lisible. Si la variance était plus haute, distinguer un vrai gain d'un bruit de run demanderait plus de 5 runs.
- **Coût des itérations** : un run sur 28 EPFL-internes coûte 2 USD et prend 6 minutes. Cinq itérations dans la semaine sans surveillance directe demandées avant chaque modification. Le smoke-test à 1 candidat (10 secondes) reste utile pour catcher les erreurs grossières de prompt.
- **Régression Biersohn** : le fix 1 a déplacé Biersohn (committee reject) de reject à waitlist. Le fix 2 a annulé cette régression sans intervention spécifique. Cohérence du signal sur ce cas, mais le système reste fragile aux retouches de prompt.

FICHIERS MODIFIÉS

◆ NOUVEAUX SCRIPTS ET RAPPORTS

Scripts d'audit (5) :
`scripts/compare_committee_vs_runs.py` (295 l.)
`scripts/rerun_epfl_internals.py` (121 l.)
`scripts/rerun_matched_only.py` (90 l.)
`scripts/before_after_epfl.py` (207 l.)
`scripts/backfill_minor_recs.py` (216 l.)

Rapports markdown générés :
`reports/committee-vs-system-2026-05-11.md`

`reports/committee-vs-system-policy-v2.md`
`reports/epfl-internal-fix-2026-05-11.md`
`reports/epfl-internal-fix-run01-only.md`
`reports/epfl-internal-fix1+2-vs-baseline.md`
`reports/epfl-internal-fix2-incremental.md`

Code modifié :
`src/agentic_admission/agents/prompts.py` (bloc EPFL-internal, deux passes)

Aucune modification d'API ni de modèle. Toutes les retouches passent par le prompt et la mesure.

SUIVI DES TÂCHES

- ✓ Script compare_committee_vs_runs.py + matrice de confusion — fait
- ✓ Script rerun_epfl_internals.py (boucle 28 internes) — fait
- ✓ Script rerun_matched_only.py (filtrer par matching parquet) — fait
- ✓ Script before_after_epfl.py (diff structurée 2 runs) — fait
- ✓ Script backfill_minor_recs.py (patch mineurs sur verdicts) — fait
- ✓ Itération 1 du prompt EPFL-interne (+1 accord) — fait
- ✓ Itération 2 du prompt EPFL-interne (+4 accords) — fait
- ✓ Email à Geraldine sur la règle officielle du seuil 4.5 — fait
- ◔ Réponse Geraldine + spec de la règle à bandes — en cours
- ◯ Audit qualitatif des 19 type-A avec le superviseur — à faire
- ◯ Corriger fixtures obsolètes test_chair.py / test_orchestrator.py — à faire

PLAN POUR LA SEMAINE PROCHAINE

Priorité haute

- Appliquer la règle à bandes que Geraldine va spécifier : `>=4.5` accept, `4.0 - 4.5` discuss, `<4.0` reject. Doit débloquer Maillard, Hegi, Croisier, Haenni en waitlist et garder Kvedarauskaite, Gruber, Nguyen, Holtz en reject (puisqu'ils sont sous 4.0).
- Réparer la suite de tests cassée par les migrations de schéma (28 tests rouges depuis la semaine 11 que j'ai laissés non-bloquants). Cible : `uv run poe test` revient vert.

- Splitter le bloc 80→40 résiduel (Type A) en deux sous-questions avec Gaétan : (a) est-ce un biais de prompt évaluateur, (b) ou un désaccord légitime entre le système et le comité sur des dossiers ambigus ?

Priorité moyenne

- Étendre l'audit comité vs système à Fall 2025-26 dès que la cohorte sera anonymisée.
- Mesurer la latence par candidat sur Fall 2025-26 ; viser <30 secondes par dossier pour un usage interactif au comité.
- Réfléchir à un format d'export que le comité peut annoter pendant la réunion (PDF imprimable ou tableau Excel pré-rempli).